



Pontificia Universidad
JAVERIANA
Bogotá

Pontificia Universidad Javeriana
Facultad de Ingeniería

Procesamiento de Datos a Gran Escala

Proyecto NewYork

Primera Entrega

Integrantes:

Gabriela Alejandra Muñoz Tovar

Mónica María Castro Benítez

Lorenzo Ramírez Calderón

Luis Alexander Pedraza Béltran

Profesor:

John Corredor Franco, PhD

2 de octubre de 2026

Bogotá D.C.

Resumen

Nueva York concentra millones de choques y denuncias, pero los totales anuales no permiten identificar en qué zonas y momentos se concentra el riesgo. Este proyecto propone un índice de urgencia para ordenar *ventanas de riesgo*, definidas por borough, franja horaria, día de la semana y condición climática, mediante un componente vial y otro de seguridad. Con Apache Spark se integraron seis fuentes públicas. Los tres conjuntos principales se acotaron al periodo 2013–2025 e incluyen 2,1 millones de choques, 6,4 millones de denuncias y 3,4 millones de arrestos. También se incorporaron la medida de pobreza NYCgov, los datos climáticos de Open-Meteo y la población de cada borough, obtenida mediante *web scraping*.

La exploración muestra que cerca de una cuarta parte de los choques deja víctimas y que la frecuencia no alcanza su máximo en los mismos periodos que la gravedad. La franja 12–18 concentra más choques, mientras que 18–24 y 00–06 presentan la mayor proporción con víctimas. Por habitante, Manhattan tiene la tasa más alta de choques y la menor proporción con víctimas. El Bronx, por su parte, ocupa el cuarto lugar en choques y el segundo en denuncias graves. La nieve se asocia con más choques por hora, pero con una menor proporción de víctimas. Además, la variación semanal de los arrestos sugiere una influencia importante de la actividad policial. Las principales limitaciones son el 30,9% de choques sin borough y la posible asignación al mediodía de denuncias con hora imprecisa. La siguiente etapa comprende la construcción de las ventanas de riesgo, el índice de urgencia y los modelos con Spark MLlib.

Palabras clave: Apache Spark, CRISP-DM, seguridad vial, criminalidad, Nueva York.

Índice

1	Entendimiento del negocio	1
1.1	Contexto y problema	1
1.2	Indicadores de contexto de la ciudad	1
1.3	Antecedentes y evidencia	2
1.4	Planteamiento del problema	3
1.5	Objetivo de negocio y objetivo analítico	4
1.6	Alcance, supuestos y criterios de éxito	4
2	Selección de los datos a utilizar	5
3	Colección y descripción de datos	6
3.1	Motor Vehicle Collisions - Crashes	7
3.2	NYPD Arrest Data	9
3.3	NYPD Complaint Data Historic	10
3.4	NYCgov Poverty Measure Data (2018)	11
3.5	Extracción de datos climáticos mediante API (BONUS)	12
3.6	Extracción de la población por borough mediante <i>web scraping</i> (BONUS)	14
4	Exploración de los datos	16
4.1	Dimensión vial	16
4.2	Dimensión climática	19
4.3	Dimensión espacial	22
4.4	Dimensión de seguridad	24
4.5	Dimensión socioeconómica	30
4.6	Síntesis de la exploración	30
5	Reporte de calidad de datos	31
6	Planteamiento de preguntas sobre los datos	33
7	Filtros, limpieza y transformación inicial	34
7.1	Filtros	34
7.2	Limpieza	34
7.3	Transformaciones	35
7.4	Resultado y pendientes	36
8	Conclusiones preliminares y próximos pasos	36

1. Entendimiento del negocio

1.1 Contexto y problema

Nueva York es una ciudad con alrededor de 8,5 millones de habitantes (NYC DCP, 2025), divididos en cinco distritos administrativos llamados boroughs: Manhattan, Brooklyn, Queens, el Bronx y Staten Island. Aunque forman una sola ciudad, son muy distintos entre sí. Por ejemplo, Manhattan es una isla de apenas 23 millas cuadradas (unos 59 km²), y aun así concentra cerca de 72.000 habitantes por milla cuadrada, mientras que Staten Island ocupa unas 58 millas cuadradas, más del doble del tamaño de Manhattan, y tiene alrededor de 8.600 habitantes por milla cuadrada (NYSDOH, 2023). Es decir, Manhattan es 8 veces más denso que Staten Island. En un borough tan denso conviven más personas, vehículos y actividad en cada calle, por lo que el riesgo de choques y de delitos no es el mismo en toda la ciudad. Por eso, comparar los boroughs solo por la cantidad de eventos que registran puede llevar a conclusiones equívocas.

La ciudad ha intentado reducir ese riesgo, sobre todo en tema de tránsito vial. En 2014 el Gobierno de la ciudad de Nueva York comenzó a implementar Vision Zero, un programa cuyo objetivo es eliminar las muertes por accidentes de tránsito mediante el rediseño de calles, el control automático de velocidad y el cumplimiento de las normas de tránsito. Los resultados muestran avance respecto a su implementación, pues en 2025 se registraron 205 muertes viales, la cifra más baja desde 1910, lo que equivale a una reducción acumulada del 31 % desde 2014 (NYC DOT, 2026a).

Sin embargo, la reducción no ha sido igual en toda la ciudad. En 2025 las muertes viales registradas bajaron un 39 % en el Bronx y un 9 % en Brooklyn, mientras que Staten Island fue el único borough en reportar aumentos, al registrar 13 muertes frente a las 12 del año anterior (NYC DOT, 2026a). Además, esta reducción tampoco ha sido constante en el tiempo. Entre enero y junio de 2026 se registraron 94 muertes viales, siete más que las 87 del mismo periodo de 2025 (NYC DOT, 2026b, 2025). Aun así, el panorama cambia según el tipo de víctima. En ese mismo semestre las muertes de peatones, uno de los grupos más vulnerables, bajaron de 53 a 46 (NYC DOT, 2026b). Es decir, un mismo periodo puede empeorar en total y mejorar para un grupo específico, algo que una cifra global no deja ver.

La seguridad ciudadana muestra algo parecido. En 2024 los arrestos por *index crimes* (los delitos mayores como homicidio, violación, robo con violencia, agresión grave, allanamiento, hurto mayor y robo de vehículo) aumentaron un 7,2 %, de 53.197 a 57.003 (NYPD, 2025a). La cifra, sin embargo, es insuficiente para saber en qué zonas, días y horarios se concentran los hechos, o si el aumento refleja más delitos o simplemente más actividad policial.

Estos ejemplos tienen algo en común, los totales y los promedios ocultan dónde y cuándo está el riesgo. Comparar solo totales puede llevar a conclusiones erróneas. Un borough puede tener más eventos solo porque tiene más habitantes. Otro puede tener menos, pero concentrados en pocos horarios o bajo ciertas condiciones climáticas. Para quien toma decisiones, la pregunta útil es dónde y cuándo conviene concentrar el patrullaje, el control de tránsito y la respuesta de emergencia. Este proyecto propone responderla con un índice de urgencia construido con datos públicos de la ciudad.

1.2 Indicadores de contexto de la ciudad

Para interpretar bien los choques y los delitos no basta contar cuántos ocurren. También es necesario considerar cuántas personas viven en cada zona y en qué condiciones socioeconómicas. Por esta razón se seleccionaron los cinco indicadores de la Tabla 1, que cumplen dos funciones: la población permite comparar boroughs de distinto tamaño, y el desempleo, ingreso, pobreza y producto de la ciudad, describen qué tan vulnerable o dinámica es la economía de cada zona.

Indicador	Valor	Periodo	Fuente	Relevancia para el proyecto
Población	8.478.000 habitantes	Julio de 2024	NYC Planning (NYC DCP, 2025)	Denominador para comparar boroughs de distinto tamaño.
Tasa de desempleo	5,2 % (de 4,5 % en Staten Island a 6,8 % en el Bronx)	2025 (promedio anual)	RGB (RGB, 2026)	Contexto económico de la demanda de seguridad.
Ingreso mediano del hogar	81.228 dólares	2024	RGB, con datos de la encuesta ACS (RGB, 2026)	Vulnerabilidad económica de cada zona.
Tasa de pobreza	18,0 % (de 11,1 % en Staten Island a 28,8 % en el Bronx)	2024	RGB, con datos de la encuesta ACS (RGB, 2026)	Permite evaluar si las zonas más urgentes son también las más vulnerables.
Producto de la ciudad (GCP)	Crecimiento real de 2,8 %	2024	RGB, con datos del BEA (RGB, 2026)	Tamaño y dinamismo de la economía.

Tabla 1: Indicadores de contexto de la ciudad de Nueva York

Estos indicadores se usarán de dos maneras. La población servirá para expresar los choques, las denuncias y los arrestos como tasas por 100.000 habitantes, una medida que permite comparar zonas de distinto tamaño en igualdad de condiciones. La pobreza y el ingreso servirán para analizar si las zonas con mayor urgencia son también las de mayor vulnerabilidad económica. Las cifras de la Tabla 1 son una referencia general de la ciudad. Los conjuntos de datos que se procesan en el proyecto, incluida la medida de pobreza de 2018, se describen en la sección 2.

1.3 Antecedentes y evidencia

La idea de que el riesgo cambia según el lugar y el momento no es nueva. Hay investigaciones previas de Nueva York sobre seguridad vial y criminalidad, que respaldan esta idea y las decisiones de las que este proyecto parte.

Seguridad Vial

Un preprint de 2025 utilizó Random Forest y XGBoost con los datos oficiales de choques para predecir la gravedad de las lesiones. Los modelos alcanzaron una exactitud cercana al 78 %, y mostraron que el tipo de persona involucrada, el momento y el lugar son variables importantes para medir la gravedad (Zhu et al., 2025). Otro estudio, publicado en *Journal of Safety Research*, analizó cómo cambian con el tiempo los patrones de densidad de choques en la red vial (Chang et al., 2024). Finalmente, un tercer trabajo analizó 998.193 choques registrados por el NYPD y comparó tres algoritmos de clasificación: kNN, *Random Forest* y Naive Bayes (Abeyratne y Halgamuge, 2020).

Estos antecedentes demuestran que los datos seleccionados permiten aplicar y comparar técnicas de aprendizaje automático para identificar patrones de riesgo. En conjunto, estas investigaciones sustentan los tres elementos centrales del componente vial del proyecto: la frecuencia de los choques, la gravedad de sus consecuencias y su variación según el lugar y el momento.

Seguridad Policial

Existen antecedentes sobre cómo asignar los recursos policiales con apoyo de modelos predictivos. Entre 2014 y 2015, el NYPD desarrolló un proyecto para probar si un modelo de riesgo territorial (*risk terrain modeling*) podía predecir distintos tipos de delito en la ciudad, con el fin de evaluar estrategias antes de desplegar recursos policiales (Williamson, 2018). De manera similar, otro estudio construyó modelos de aprendizaje de máquina para predecir delitos con datos de 2018 y apoyar la asignación de recursos (Elluri et al., 2019). En ese caso las variables climáticas tuvieron un papel despreciable, así que el clima se tratará con cautela en el componente de seguridad.

Vision Zero

Finalmente, respecto a Vision Zero, la evidencia muestra que dirigir las intervenciones a zonas específicas da resultados medibles. Un estudio analizó si el programa redujo las lesiones por tránsito entre personas de bajos ingresos. Para ello usaron registros de Medicaid, el programa público de seguro de salud de Estados Unidos para personas de bajos ingresos, que guarda cada atención médica de sus afiliados. Así pudieron contar las personas atendidas por lesiones de tránsito antes y después del programa. Encontraron que, tras su implementación, hubo en promedio 77,5 lesiones menos por cada 100.000 personas al año; es decir, en un grupo de un millón de personas, unas 775 lesiones menos cada año. Los mayores efectos se observaron entre residentes afroamericanos, aunque esos beneficios se revirtieron durante la pandemia (Dragan et al., 2024). Otro estudio se centró en tramos de calle específicos que la ciudad rediseñó como parte de Vision Zero. En él se compararon los choques con peatones heridos en esos tramos antes y después de las obras, y encontraron que, dos años después, estos choques habían disminuido en un 6,1 % (Sehtman-Shachar et al., 2024).

Intervenir de forma dirigida da resultados medibles, pero los efectos no son iguales para todos los grupos ni se mantienen siempre en el tiempo. Esto explica por qué conviene identificar dónde y cuándo concentrar los recursos, y por qué la pobreza se incluye como contexto del análisis.

En conjunto, estos antecedentes indican que el riesgo vial y el delictivo varían según el lugar y el momento, y que intervenir de forma dirigida funciona. Este proyecto toma esa idea como punto de partida y propone un índice que identifique, para toda la ciudad, las combinaciones de zona, hora, día y clima donde la intervención es más urgente.

1.4 Planteamiento del problema

Este proyecto está dirigido al gobierno de Nueva York y a las agencias que ejecutan sus decisiones, como el NYPD, el Departamento de Transporte y los servicios de emergencia. De todos los problemas que atienden, los que más les preocupan son los accidentes viales y los delitos, medidos a través de las denuncias y los arrestos.

Para decidir cómo usar sus recursos, estas entidades cuentan con reportes públicos como los balances anuales de Vision Zero y de arrestos que se presentaron en la sección 1 (NYC DOT, 2026a; NYPD, 2025a). Estos reportes entregan cifras agregadas por mes o por año y, en algunos casos, por borough. Con ese nivel de detalle se puede saber *cuánto* ocurre, pero no *cuándo* ni *bajo qué condiciones*: no muestran en qué días, franjas horarias o climas se concentra el riesgo. Sin esa información, la decisión de cuántos agentes enviar, dónde hacer controles de tránsito o dónde reforzar la respuesta de emergencia se toma con una visión demasiado general.

El problema de negocio consiste, entonces, en identificar y ordenar las combinaciones de lugar y momento según su nivel de urgencia, de modo que los recursos se asignen primero donde y cuando más se necesitan, y esa asignación se apoye en datos. En otras palabras, el proyecto busca responder una pregunta: *¿en qué combinaciones de borough, franja horaria, día*

de la semana y clima conviene concentrar el patrullaje, el control de tránsito y la respuesta de emergencia?

Como grupo consultor, se propone responderla con un marco de trabajo en tres pasos. Primero, dividir la ciudad en *ventanas de riesgo*, es decir, combinaciones de borough, franja horaria, día de la semana y condición climática. Segundo, medir en cada ventana el riesgo vial y el de seguridad con datos públicos, de modo que las ventanas sean comparables entre sí aunque tengan distinta población o hayan durado distinto tiempo. Tercero, combinar ambas medidas en un índice de urgencia que permita al cliente priorizar dónde y cuándo actuar.

1.5 Objetivo de negocio y objetivo analítico

- **Objetivo de negocio.** Apoyar al gobierno de Nueva York en la priorización de recursos operativos, como el patrullaje, el control de tránsito y la respuesta de emergencia, hacia las ventanas de mayor riesgo, en lugar de distribuir estos recursos de manera uniforme en toda la ciudad.
- **Objetivo analítico.** Construir un índice de urgencia para ordenar las ventanas de riesgo en Nueva York. Cada ventana estará definida por la combinación de un borough, una de cuatro franjas horarias de seis horas, un día de la semana y una condición climática. El índice tendrá dos componentes principales. El componente vial se calculará a partir de la frecuencia de choques y de la proporción de accidentes en los que hubo personas heridas o fallecidas. El componente de seguridad se basará en las denuncias por delitos graves.

Las frecuencias se calcularán considerando las horas observadas y se ajustarán según la población de cada borough. Después, las medidas se transformarán a una escala entre 0 y 1 y se combinarán mediante los pesos definidos por el equipo. Los arrestos no se utilizarán como una medida directa del riesgo, sino como una referencia para comparar la actividad policial con las denuncias y evitar interpretar automáticamente una mayor presencia policial como una mayor incidencia delictiva. La pobreza se utilizará únicamente como información de contexto.

En la entrega final se incorporarán técnicas de aprendizaje de máquina mediante Spark MLlib, incluyendo una técnica supervisada y otra no supervisada, con el propósito de complementar el análisis.

1.6 Alcance, supuestos y criterios de éxito

Alcance

- El periodo de análisis va de 2013 a 2025.
- El nivel espacial utilizado es el borough.
- Las fuentes consideradas incluyen choques, denuncias, arrestos, pobreza, clima y población (sección 2).

Supuestos y limitaciones.

- Los datos corresponden a hechos reportados a la policía, por lo que pueden existir eventos que no hayan sido registrados.
- Los arrestos no contienen información sobre la hora, por lo que no se utilizarán para construir las franjas horarias.
- La información sobre pobreza corresponde a 2018 y se utilizará únicamente como contexto.

- Los datos climáticos provienen de una grilla de varios kilómetros, por lo que se utilizará un punto representativo para cada borough.
- La población se mantendrá como denominador fijo durante todo el periodo de análisis.
- El periodo de estudio incluye la pandemia, que modificó las condiciones del tránsito. La disminución del número de vehículos estuvo acompañada por un aumento de la velocidad y de la gravedad de los choques (Cappellari y Weber, 2022). Además, los niveles de choques posteriores se mantuvieron por debajo de la mitad de los niveles registrados antes de la pandemia (Mittal y Lim, 2024). Este cambio deberá tenerse en cuenta al interpretar los resultados.

Criterios de éxito.

Se considerará que el índice es útil si cumple los siguientes criterios:

- Es reproducible, es decir, puede calcularse mediante el mismo procedimiento en el en Apache Spark a partir de los datos públicos.
- El orden de las ventanas se mantiene relativamente estable cuando cambian los pesos asignados a los componentes vial y de seguridad (pregunta 9).
- La mitad de la urgencia total se concentra en un número reducido de ventanas (pregunta 10).

2. Selección de los datos a utilizar

Para construir el índice de urgencia se utilizarán varias fuentes de información. La mayoría proviene del portal de datos abiertos de Nueva York y cada una cumple una función diferente: medir el riesgo, ajustar las comparaciones o aportar contexto. La selección podrá revisarse en la entrega final si los resultados del análisis muestran que alguna fuente debe incorporarse, reemplazarse o descartarse.

Fuentes que miden el riesgo

- **Motor Vehicle Collisions – Crashes:** Portal de datos abiertos de NYC. Esta será la fuente principal para analizar los siniestros viales. Cada registro indica la fecha, la hora y el lugar del choque, los posibles factores que contribuyeron al evento y la cantidad de personas heridas o fallecidas, con conteos específicos para peatones, ciclistas y ocupantes de vehículos. El conjunto cubre desde 2012, y para el análisis se usan los años completos de 2013 a 2025. Esta información permitirá construir el componente de riesgo vial e identificar las zonas, los días y las franjas horarias con mayor concentración de accidentes. Además, permitirá diferenciar la frecuencia de los choques de la gravedad de sus consecuencias y relacionar cada evento con las condiciones climáticas presentes en ese momento.
- **NYPD Complaint Data Historic:** Portal de datos abiertos de NYC. Este conjunto contiene los hechos delictivos reportados al NYPD e incluye información sobre el tipo de incidente, la fecha, la hora y el lugar en el que ocurrió. Su incorporación permite analizar la demanda de seguridad en cada zona, incluso cuando el reporte no produjo un arresto. Será la fuente principal del componente de seguridad porque permite calcular la frecuencia de denuncias por delitos graves y es el conjunto de seguridad que contiene la hora necesaria para formar las franjas horarias. Además, complementa los datos de arrestos y ayuda a evitar que una mayor presencia o actividad policial se interprete automáticamente como un mayor nivel de

delincuencia. La comparación de ambas fuentes permitirá identificar con mayor precisión las zonas y los periodos que requieren mayor atención.

- **NYPD Arrest Data (Historic):** Portal de datos abiertos de NYC. Este conjunto permite incorporar la actividad policial al análisis de seguridad. Cada fila indica la fecha, el lugar y el motivo de un arresto; sin embargo, no incluye la hora del evento. Cubre desde 2006 hasta diciembre de 2025. Por esta razón, los arrestos no se usarán como una medida directa del riesgo ni para construir las franjas horarias. En cambio, servirán para comparar, por borough y día, la cantidad de arrestos con las denuncias registradas. Esta comparación permitirá reconocer si un número alto de arrestos refleja una mayor concentración de hechos reportados o una mayor presencia y actuación de la policía en la zona.

Fuentes de contexto y ajuste

- **Open-Meteo Historical API:** Open-Meteo. Es una fuente gratuita de condiciones climáticas históricas por hora y coordenada, con información disponible desde 1940. Para este proyecto se solicitaron la temperatura, la precipitación, las nevadas, el código de condición climática, la visibilidad y la velocidad del viento para un punto representativo por borough, entre 2013 y el 20 de septiembre de 2026; el análisis usa los años 2013 a 2025. La visibilidad llegó vacía en todos los registros y se descartó. El clima formará parte de la definición de cada ventana y permitirá evaluar si determinadas condiciones aumentan la frecuencia o la gravedad de los siniestros. También ayudará a distinguir si el riesgo observado se relaciona principalmente con la ubicación o con las condiciones presentes en el momento del evento.
- **Población por borough mediante *web scraping*:** se utiliza la tabla de población por condado y sexo del Registro de Cáncer del Estado de Nueva York (NYSDOH, s.f.), que reporta el promedio anual del periodo 2019–2023 y se extrajo de una imagen de la página mediante OCR (sección 3.6). La población servirá como denominador para comparar zonas de distinto tamaño, pues un borough con más habitantes puede registrar más eventos sin que esto implique necesariamente un mayor riesgo individual. Esta tabla no incluye la superficie ni la densidad, que en la sección 1 se toman únicamente como dato de contexto de la tabla de estimaciones del Departamento de Salud del estado.
- **NYCgov Poverty Measure Data (2018):** Portal de datos abiertos de NYC. Este conjunto permite incorporar la pobreza como una característica general de cada borough. Contiene información sobre las personas y sus hogares, junto con pesos muestrales que permiten obtener resultados representativos para la población. Aunque los datos corresponden únicamente a 2018, se consideran útiles porque las condiciones socioeconómicas suelen cambiar de manera gradual y pueden emplearse como una referencia estable del territorio. La pobreza no se utilizará para predecir cuándo ocurrirá un choque o un delito ni formará parte de la fórmula del índice. Se empleará como información de contexto para evaluar si los boroughs con mayor vulnerabilidad socioeconómica también concentran las ventanas con mayor urgencia, más siniestros viales graves o más hechos relacionados con la seguridad.

3. Colección y descripción de datos

El procesamiento de los datos se realizó con Apache Spark 4.0.4 mediante su interfaz para Python (PySpark), desde un cuaderno Jupyter que se entrega como anexo de este documento. La sesión, denominada **ProyectoNY**, se configuró con 1 GB de memoria y 4 núcleos por *executor*. La Tabla 2 resume las características reportadas por la sesión.

Característica	Valor
Versión de Apache Spark	4.0.4
Modo de ejecución (<i>master</i>)	<code>local[*]</code>
Paralelismo por defecto	4 tareas en paralelo
Memoria por <i>executor</i>	1 GB
Núcleos por <i>executor</i>	4
Sistema de archivos	Disco local de la máquina virtual (<code>file:///</code>)
Ubicación de los datos	<code>/opt/cluster/proyecto_ny/data/raw/</code>

Tabla 2: Características del entorno de procesamiento

Para esta primera entrega, el procesamiento se ejecutó con Spark en modo local (`local[*]`) dentro de una máquina virtual, utilizando los núcleos disponibles para ejecutar tareas en paralelo.

Los conjuntos Motor Vehicle Collisions – Crashes, NYPD Arrests Data, NYPD Complaint Data Historic y NYCgov Poverty Measure se descargaron en formato CSV del portal de datos abiertos de Nueva York (NYC Open Data, s.f.-a,s,s,s) y se transfirieron a la máquina virtual mediante SSH. El equipo generó los datos climáticos en formato Parquet y los datos de población en formato CSV; ambos conjuntos se cargaron en el mismo directorio. La Tabla 3 resume las seis fuentes de datos.

Conjunto	Registros	Atributos	Periodo	Formato
Choques (<i>Crashes</i>)	2.269.187	29	Desde 2012	CSV
Denuncias (<i>Complaints</i>)	10.071.507	35	Hasta 2025	CSV
Arrestos (<i>Arrests</i>)	6.264.978	19	2006–2025	CSV
Pobreza NYCgov	68.273	61	2018	CSV
Clima (Open-Meteo)	601.320	12	2013 a septiembre de 2026	Parquet
Población por borough	5	4	Promedio 2019–2023	CSV

Tabla 3: Conjuntos de datos cargados en Spark

3.1 Motor Vehicle Collisions - Crashes

Este conjunto contiene un registro por cada choque vehicular reportado por la policía en Nueva York y consta de 2.269.187 registros y 29 atributos. Cada fila indica cuándo y dónde ocurrió el siniestro, cuántas personas resultaron heridas o fallecieron y qué factores y vehículos intervinieron. Es la fuente principal del componente de riesgo vial. Algunos campos de texto contienen saltos de línea delimitados por comillas; una lectura convencional interpreta esos saltos como separadores de registros y divide una observación en dos filas. Además, sin la configuración adecuada, tres columnas numéricas se interpretan como texto. Por ello, el archivo se leyó con las opciones `multiLine` y `escape`. Con esta configuración, las columnas de conteo se interpretan como enteros y la hora como una marca de tiempo que incluye una fecha ficticia; por tanto, solo se conservan la hora y los minutos. La fecha del choque permanece como texto en formato MM/DD/AAAA y se convierte durante la etapa de limpieza.

Atributo	Tipo	Descripción y aporte
CRASH DATE	string	Fecha del choque (MM/DD/AAAA). Permite derivar día de la semana, mes y año para las ventanas temporales y para cruzar con el clima.
CRASH TIME	timestamp	Hora del choque (formato 24 h). Spark la lee como fecha-hora con una fecha ficticia, por lo que solo se usan la hora y los minutos. Permite construir las franjas horarias del índice de riesgo.
BOROUGH	string	Distrito de la ciudad donde ocurrió el choque. Es la variable de delimitación espacial del proyecto, aunque tiene un 30,47% de faltantes.
ZIP CODE	string	Código postal de la ubicación. Ofrece una granularidad espacial más fina que el distrito.
LATITUDE	string	Latitud del choque (con coma decimal). Junto con la longitud permite ubicar el evento y recuperar el borough cuando falta.
LONGITUDE	string	Longitud del choque (con coma decimal). Cumple la misma función que la latitud.
LOCATION	string	Par (latitud, longitud) en un solo texto. Es redundante con las dos columnas anteriores.
ON STREET NAME	string	Calle donde ocurrió el choque. Sirve para identificar vías o corredores con alta siniestralidad.
CROSS STREET NAME	string	Calle transversal más cercana. Junto con la anterior identifica intersecciones críticas.
OFF STREET NAME	string	Dirección cuando el choque ocurrió fuera de la vía (por ejemplo, un parqueadero). Tiene un 82,07% de faltantes.
NUMBER OF PERSONS INJURED	integer	Total de personas heridas. Es la base de la gravedad del siniestro.
NUMBER OF PERSONS KILLED	integer	Total de personas muertas. Es el componente más grave de la severidad.
NUMBER OF PEDESTRIANS INJURED	integer	Peatones heridos. Permite analizar el riesgo para usuarios vulnerables.
NUMBER OF PEDESTRIANS KILLED	integer	Peatones muertos.
NUMBER OF CYCLIST INJURED	integer	Ciclistas heridos.
NUMBER OF CYCLIST KILLED	integer	Ciclistas muertos.
NUMBER OF MOTORIST INJURED	integer	Conductores y ocupantes de vehículos heridos.
NUMBER OF MOTORIST KILLED	integer	Conductores y ocupantes de vehículos muertos.
CONTRIBUTING FACTOR VEHICLE 1	string	Factor que contribuyó al choque según el vehículo 1 (exceso de velocidad, distracción, pavimento resbaladizo, etc.). Aporta las causas al análisis.
CONTRIBUTING FACTOR VEHICLE 2-5	string	Factores del segundo al quinto vehículo. Están casi vacíos a partir del tercero (más del 92% de faltantes).
COLLISION_ID	integer	Identificador único del choque. Sirve como llave primaria para verificar duplicados.
VEHICLE TYPE CODE 1	string	Tipo del vehículo 1 (sedán, camioneta, moto, etc.). Permite ver qué vehículos se asocian a choques graves.
VEHICLE TYPE CODE 2-5	string	Tipo del segundo al quinto vehículo. Con muchos faltantes, por lo que se descartan para el objetivo.

Tabla 4: Diccionario de atributos - Motor Vehicle Collisions - Crashes

3.2 NYPD Arrest Data

Este conjunto contiene 6.264.978 registros de arrestos efectuados por la policía de Nueva York entre 2006 y 2025, descritos mediante 19 atributos. Cada fila indica la fecha, el lugar y el motivo del arresto, además de algunas características demográficas de la persona arrestada. Los datos se utilizan como referencia de la actividad policial y no como componente directo del índice de urgencia. El conjunto incluye la fecha del arresto, pero **no la hora**; por ello, el análisis delictivo por franjas horarias se basa en el conjunto de denuncias. Además, **Latitude** y **Longitude** se interpretaron como texto con coma decimal y deben convertirse a valores numéricos.

Atributo	Tipo	Descripción y aporte
ARREST_KEY	integer	Identificador único del arresto. Sirve como llave primaria.
ARREST_DATE	string	Fecha del arresto (MM/DD/AAAA). Permite derivar día de la semana y mes para las ventanas temporales.
PD_CD	integer	Código interno de la clasificación detallada del delito. Complementa la descripción textual.
PD_DESC	string	Descripción detallada del delito (por ejemplo, “strangulation 1st”). Permite distinguir subtipos dentro de una misma categoría.
KY_CD	integer	Código de la categoría general del delito. Sirve para agrupar delitos de forma consistente.
OFNS_DESC	string	Descripción de la categoría general del delito (por ejemplo, “felony assault”). Es la base para clasificar los arrestos por tipo.
LAW_CODE	string	Artículo de la ley penal que sustenta el arresto. Aporta trazabilidad legal.
LAW_CAT_CD	string	Nivel de gravedad legal: delito grave (F), delito menor (M), violación (V) o infracción (I). Permite ponderar la gravedad del arresto en el índice.
ARREST_BORO	string	Distrito del arresto, codificado con una letra (B, K, M, Q, S). Es la variable de delimitación espacial.
ARREST_PRECINCT	integer	Precinto policial donde se hizo el arresto. Da una granularidad más fina que el distrito y coincide con la unidad operativa de despliegue.
JURISDICTION_CODE	integer	Código de la jurisdicción responsable (patrulla, tránsito, vivienda pública u otras agencias).
AGE_GROUP	string	Rango de edad de la persona arrestada. Es una variable demográfica descriptiva.
PERP_SEX	string	Sexo de la persona arrestada.
PERP_RACE	string	Grupo étnico-racial de la persona arrestada, tal como lo registra la policía.
X_COORD_CD	double	Coordenada X en el sistema plano del estado de Nueva York (pies).
Y_COORD_CD	double	Coordenada Y en el mismo sistema.
Latitude	string	Latitud del arresto (con coma decimal). Permite ubicar el evento y asignarlo a una zona.
Longitude	string	Longitud del arresto (con coma decimal).
Lon_Lat	string	Punto geográfico en formato WKT (<i>POINT</i>). Es redundante con latitud y longitud.

Tabla 5: Diccionario de atributos - NYPD Arrest Data

3.3 NYPD Complaint Data Historic

Este conjunto contiene 10.071.507 denuncias reportadas a la policía, descritas mediante 35 atributos. A diferencia de los datos de arrestos, permite medir la incidencia delictiva reportada independientemente de que los hechos hayan producido una actuación policial. Además, es el único conjunto de seguridad que incluye la hora de ocurrencia. Los datos presentan varios problemas de formato que se corregirán durante la limpieza: los valores faltantes aparecen como el texto (null); X_COORD_CD se almacena como texto con puntos de miles, por ejemplo, 1.042.801; y Y_COORD_CD se interpretó erróneamente como un número decimal, por lo que un valor como 181.715 corresponde en realidad a 181715.

Atributo	Tipo	Descripción y aporte
CMPLNT_NUM	string	Identificador único de la denuncia. Sirve como llave primaria.
CMPLNT_FR_DT	string	Fecha de inicio de los hechos. Es la fecha principal para las ventanas temporales.
CMPLNT_FR_TM	string	Hora de inicio de los hechos. Permite construir las franjas horarias del componente delictivo.
CMPLNT_TO_DT	string	Fecha de fin de los hechos, cuando el delito ocurrió en un intervalo. Tiene un 18,62% de faltantes.
CMPLNT_TO_TM	string	Hora de fin de los hechos, con la misma limitación.
ADDR_PCT_CD	integer	Precinto policial de la ubicación de los hechos. Es la unidad operativa para el despliegue de patrullaje.
RPT_DT	string	Fecha en que se reportó la denuncia. Permite medir el retraso entre el hecho y el reporte.
KY_CD	integer	Código de la categoría general del delito.
OFNS_DESC	string	Descripción de la categoría general del delito. Sirve para clasificar las denuncias por tipo.
PD_CD	integer	Código de la clasificación detallada del delito.
PD_DESC	string	Descripción detallada del delito.
CRM_ATPT_CPTD_CD	string	Indica si el delito se consumó o quedó en intento. Permite diferenciar hechos completados.
LAW_CAT_CD	string	Gravedad legal: felony, misdemeanor o violation. Permite ponderar el delito en el índice.
BORO_NM	string	Distrito donde ocurrió el hecho. Es la variable de delimitación espacial.
LOC_OF_OCCUR_DESC	string	Ubicación relativa al edificio (dentro, frente, atrás, etc.).
PREM_TYP_DESC	string	Tipo de lugar (calle, vivienda, tienda, estación, etc.). Permite ver en qué entornos se concentra el delito.
JURIS_DESC	string	Descripción de la jurisdicción responsable (policía municipal, vivienda, tránsito u otra).
JURISDICTION_CODE	integer	Código numérico de la jurisdicción.
PARKS_NM	string	Nombre del parque donde ocurrió el hecho, si aplica. Casi vacío (99,56%).
HADEVELOPT	string	Nombre del complejo de vivienda pública, si aplica. Casi vacío (99,65%).
HOUSING_PSA	string	Zona de servicio policial de vivienda pública. Tiene un 92,63% de faltantes.
X_COORD_CD	string	Coordenada X en el sistema plano del estado (pies), con formato numérico por corregir.
Y_COORD_CD	double	Coordenada Y en el mismo sistema, con la lectura decimal errónea antes descrita.
SUSP_AGE_GROUP	string	Rango de edad del sospechoso. Tiene un 46,75% de faltantes.
SUSP_RACE	string	Grupo étnico-racial del sospechoso, según el registro policial.
SUSP_SEX	string	Sexo del sospechoso.

Atributo	Tipo	Descripción y aporte
TRANSIT_DISTRICT	integer	Distrito de tránsito, si el hecho ocurrió en el sistema de transporte. Solo aplica a un pequeño subconjunto.
Latitude	string	Latitud del hecho (con coma decimal). Permite ubicar el evento y recuperar el distrito cuando falta.
Longitude	string	Longitud del hecho (con coma decimal).
Lat_Lon	string	Par (latitud, longitud) en un solo texto. Es redundante con las dos columnas anteriores.
PATROL_BORO	string	Distrito de patrullaje (por ejemplo, “Patrol Boro Queens South”). Es más fino que el borough y refleja la organización operativa.
STATION_NAME	string	Nombre de la estación de transporte, si aplica. Tiene un 97,42% de faltantes.
VIC_AGE_GROUP	string	Rango de edad de la víctima.
VIC_RACE	string	Grupo étnico-racial de la víctima, según el registro policial.
VIC_SEX	string	Sexo de la víctima.

Tabla 6: Diccionario de atributos - NYPD Complaint Data Historic

3.4 NYCgov Poverty Measure Data (2018)

Este conjunto contiene 68.273 registros y 61 atributos de la muestra utilizada para calcular la medida de pobreza de la ciudad de Nueva York en 2018. Cada fila describe a una persona y su hogar mediante características demográficas, laborales y educativas; información sobre ingresos, gastos y beneficios; y su condición de pobreza según las medidas municipal y oficial. Debido a que los datos provienen de una encuesta de hogares y no de un registro administrativo, cada fila incluye un peso muestral (PWGTP) que indica cuántas personas de la población representa. Sin aplicar este peso, los resultados describirían únicamente la muestra y no serían representativos de la ciudad. En el proyecto, estos datos se utilizan como contexto socioeconómico por borough para evaluar si las ventanas de mayor urgencia coinciden con las zonas de mayor pobreza.

Durante la lectura del archivo, Spark infirió 34 columnas como enteras, 3 como decimales y 24 como texto. La mayoría de las variables monetarias, entre ellas los ingresos, los gastos y los impuestos, se interpretaron como texto porque emplean el punto como separador de miles y la coma como separador decimal; por ejemplo, 81.417,961. Estas columnas deben convertirse a un tipo numérico durante la limpieza. La variable `Off_Threshold` se interpretó como decimal, aunque valores como 13.064 sugieren que el punto funciona como separador de miles; por ello, su formato debe verificarse antes del análisis. La Tabla 7 agrupa y describe los atributos del conjunto.

Atributo	Tipo	Descripción y aporte
Boro	integer	Borough de residencia, codificado con un número. Es la variable de delimitación espacial y permite calcular la pobreza por borough.
NYCgov_Pov_Stat	integer	Condición de pobreza de la persona según la medida de la ciudad (1 = en pobreza, 2 = no). Es la variable principal del contexto socioeconómico.
NYCgov_Income, NYCgov_Threshold	string	Ingreso según la medida de la ciudad y umbral de pobreza con el que se compara. Permiten medir qué tan lejos está cada persona de la línea de pobreza.
Off_Pov_Stat, Off_Threshold	integer, double	Condición de pobreza y umbral según la medida oficial. Permiten comparar las dos medidas.

Atributo	Tipo	Descripción y aporte
PWGTP, WGTP	double	Peso muestral de la persona y del hogar: cuántas personas u hogares de la ciudad representa cada fila. Es necesario para expandir los resultados a la población.
SERIALNO, SPORDER	integer	Número de hogar y orden de la persona dentro del hogar. Identifican a cada persona.
Povunit_ID, Povunit_Rel, NYCgov_REL, REL, NP, HHT, FamType_PU	integer	Unidad de pobreza a la que pertenece la persona, su relación con el jefe del hogar, y el tamaño y tipo de hogar.
AGEP, AgeCateg, SEX, CIT, CitizenStatus, Ethnicity, EducAttain, SCH, SCHG, SCHL, LANX, ENG, DIS, MAR, MSP	integer	Características demográficas y educativas de la persona (edad, sexo, ciudadanía, etnia, educación, idioma, discapacidad y estado civil). Son variables descriptivas.
ESR, WKW, WKHP, FTPTWork, TotalWorkHrs_PU, JWTR	integer	Situación laboral: condición de empleo, semanas y horas trabajadas, y medio de transporte al trabajo.
TEN, RNTP_adj, MRGP_adj	integer, string	Tenencia de la vivienda y pagos de alquiler e hipoteca.
WAGP_adj, SEMP_adj, INTP_adj, RETP_adj, SSP_adj, SSIP_adj, PA_adj, OI_adj, PreTaxIncome_PU	string	Componentes del ingreso ajustado (salarios, trabajo independiente, intereses, jubilación, seguridad social, ingreso suplementario, asistencia pública y otros ingresos) e ingreso antes de impuestos de la unidad.
EST_Childcare, EST_Commuting, EST_EITC, EST_FICAtax, EST_HEAP, EST_Housing, EST_IncomeTax, EST_MOOP, EST_Nutrition, EST_PovGap, EST_PovGapIndex	string	Estimaciones de gastos, impuestos y beneficios que la medida de la ciudad suma o resta al ingreso (cuidado infantil, transporte al trabajo, crédito tributario, impuestos, ayuda energética, vivienda, gastos médicos y nutrición) y brecha de pobreza.

Tabla 7: Diccionario de atributos (agrupados) – NYCgov Poverty Measure Data (2018)

3.5 Extracción de datos climáticos mediante API (BONUS)

Para incorporar la dimensión climática al análisis de las ventanas de riesgo, el equipo consultó la API de datos históricos de Open-Meteo (Zippenfenig, 2023). El servicio recibe peticiones HTTP y devuelve archivos JSON con series horarias para las coordenadas solicitadas, sin exigir registro ni clave de acceso. Los datos proceden de modelos de reanálisis como ERA5 (Hersbach et al., 2020); por ello, cada valor corresponde a la celda de la cuadrícula del modelo más cercana al punto consultado y no a una medición directa de una estación meteorológica.

Se consultó un punto representativo por cada uno de los cinco boroughs (Tabla 8), con una llamada por borough y por año entre 2013 y 2026 (el último año, hasta el 20 de septiembre) y una pausa de un segundo entre llamadas para respetar los límites del servicio, es decir, 70 llamadas. El resultado son 601.320 registros horarios (120.264 por borough), guardados en formato Parquet y cargados en Spark junto con los demás conjuntos. Para el análisis se usan únicamente los años 2013 a 2025, igual que en los choques. La Tabla 9 resume los parámetros de la petición.

Borough	Latitud	Longitud
Manhattan	40,7831	−73, 9712
Brooklyn	40,6782	−73, 9442
Queens	40,7282	−73, 7949
Bronx	40,8448	−73, 8648
Staten Island	40,5795	−74, 1502

Tabla 8: Coordenadas del punto representativo de cada borough

Parámetro	Valor utilizado
Endpoint	archive-api.open-meteo.com/v1/archive
Coordenadas	Un punto por borough (Manhattan, Brooklyn, Queens, Bronx y Staten Island)
Rango de fechas	2013-01-01 a 2026-09-20 (el análisis usa hasta 2025-12-31)
Variables horarias	temperature_2m, precipitation, snowfall, weather_code, visibility, wind_speed_10m
Zona horaria	America/New_York, para que coincida con la hora local de choques y denuncias

Tabla 9: Parámetros de la extracción climática con Open-Meteo

A partir de la respuesta de la API se generaron las columnas **fecha**, **hora**, **mes** y **año**, que funcionan como claves de unión entre los datos climáticos, los choques y las denuncias. El código numérico **weather_code**, definido por la Organización Meteorológica Mundial, se convirtió en categorías interpretables mediante la columna **condicion**: despejado (códigos 0 y 1), nublado (2 y 3), niebla (45 y 48), lluvia (51 a 67 y 80 a 82), nieve (71 a 77, 85 y 86), tormenta (95 o más) y otro. En los datos extraídos solo se observaron cuatro categorías: despejado, nublado, lluvia y nieve. La columna **condicion** definirá la dimensión climática de las ventanas de riesgo. Por otra parte, **visibility** presentó valores faltantes en los 601.320 registros (100%), por lo que se descartó del análisis.

La Tabla 10 presenta las horas de exposición a cada condición climática por borough. Esta distribución es necesaria porque las condiciones adversas ocurren con mucha menor frecuencia que el tiempo despejado o nublado. En los cinco boroughs, la lluvia representa cerca del 13 % de las horas observadas y la nieve alrededor del 2 %. Por esta razón, los conteos brutos de choques no son directamente comparables entre condiciones. Sin embargo, la cantidad de horas registrada permite calcular tasas de siniestros por hora y comparar la proporción de choques con víctimas. Estas diferencias se interpretarán como asociaciones y no como efectos causales del clima.

Borough	Despejado	Nublado	Lluvia	Nieve
Bronx	49.865	51.947	16.198	2.254
Brooklyn	49.990	52.114	16.084	2.076
Manhattan	49.677	52.372	15.985	2.230
Queens	50.056	51.859	16.167	2.182
Staten Island	49.960	52.275	15.979	2.050

Tabla 10: Horas por condición climática y borough, 2013 a septiembre de 2026

Para el cruce con los choques se utilizó como referencia para toda la ciudad la serie de Manhattan entre 2013 y 2025. De sus 113.952 horas, 47.075 fueron despejadas, 49.680 nubladas, 15.100 con lluvia y 2.097 con nieve.

La Figura 1 muestra la precipitación total anual por borough entre 2013 y 2026. La serie de 2026 llega hasta el 20 de septiembre, por lo que sus valores más bajos se deben al periodo incompleto y no a una reducción de la lluvia. El año 2018 fue el más lluvioso, con acumulados de entre 1.650 y 1.730 mm, mientras que 2016 fue el más seco, con cerca de 900 mm. Después de 2018, la precipitación se mantuvo por encima de los niveles observados entre 2013 y 2016 y presentó un segundo pico en 2023, con valores de entre 1.410 y 1.550 mm.




Figura 1: Precipitación total anual por borough, 2013 a 2026 (2026 hasta el 20 de septiembre)

Las series de los cinco boroughs siguen patrones casi idénticos, con aumentos y disminuciones en los mismos años. La diferencia entre ellos suele ser inferior a 150 mm anuales y alcanza un máximo cercano a 170 mm en 2025. Por tanto, el clima permite distinguir cuándo ocurrieron las precipitaciones, pero aporta poca información para diferenciarlas espacialmente. Esto se debe a la proximidad de los puntos consultados y a la resolución de varios kilómetros de la grilla. Por esta razón, el clima se cruza con los choques y las denuncias por fecha y hora, no por borough.

3.6 Extracción de la población por borough mediante *web scraping* (BONUS)

Para comparar boroughs de distinto tamaño, los choques, las denuncias y los arrestos se expresarán como tasas por 100.000 habitantes. Para ello se necesita la población de cada borough, que se obtuvo mediante *web scraping* y reconocimiento óptico de caracteres (OCR).

Fuente. El enlace original del Registro de Cáncer del Estado de Nueva York, Neighborhood Population, ya no contenía la información esperada. En el mismo sitio se encontró la página de estimaciones de población (NYSDOH, s.f.), que presenta los datos mediante una visualización dinámica de Tableau y no como una tabla HTML. El código fuente permitió localizar una imagen PNG con la tabla completa. Según su encabezado, esta reporta la población promedio anual por condado y sexo entre 2019 y 2023, a partir de datos del programa SEER del Instituto Nacional del Cáncer de Estados Unidos.

La Figura 2 reproduce el encabezado y la fila de total de la ciudad, que sirve para verificar la suma de los cinco condados usados (segunda fila).

New York County/NYC Neighborhood Cancer Statistics Dashboards			
Rate by Race/Ethnicity	Rate by County	Trend by County	Stage by County
Survival by County	Rate by PUMA	Prevalence	Population by County/PUMA
Population Estimates by County and Public Use Microdata Area (PUMA)			
Average Annual Population Counts by County and Sex, 2019-2023			
County	Female	Male	Male and Female
New York State	10,195,020	9,728,690	19,923,710
New York City	4,447,164	4,106,515	8,553,679
New York State excl. NYC	5,747,857	5,622,175	11,370,031

Figura 2: Fragmento de la tabla del Registro de Cáncer de Nueva York.

Procedimiento.

1. **Descarga:** se localizó la imagen en el código HTML y se descargó con las bibliotecas *Requests* y *BeautifulSoup*.
2. **Lectura:** con *Pytesseract* (que requiere el programa Tesseract instalado en el sistema) se aplicó OCR para reconocer los condados y sus valores de población femenina, masculina y total, conservando las coordenadas de cada elemento.
3. **Reconstrucción:** como el OCR no conserva la estructura de la tabla, se usaron esas coordenadas para agrupar en una misma fila los valores de cada condado y para separar la tabla de condados de la de áreas PUMA.
4. **Aceptación:** una fila solo se aceptó si la suma de mujeres y hombres coincidía con el total (diferencia máxima de una persona).
5. **Asignación:** cada condado se asoció a su borough (Bronx, Kings, New York, Queens y Richmond corresponden a Bronx, Brooklyn, Manhattan, Queens y Staten Island). El resultado se guardó en un archivo CSV y se cargó en Spark.

Borough	Condado	Mujeres	Hombres	Total	Diferencia
Bronx	Bronx	750.962	672.768	1.423.729	+1
Brooklyn	Kings	1.390.435	1.265.135	2.655.570	0
Manhattan	New York	855.829	782.195	1.638.025	-1
Queens	Queens	1.197.626	1.144.421	2.342.047	0
Staten Island	Richmond	252.311	241.997	494.308	0

Tabla 11: Población anual promedio por borough, 2019–2023, según el Registro de Cáncer del Estado de Nueva York. Diferencia = Mujeres + Hombres – Total.

Validación y alcance. El criterio de aceptación basado en sumas reduce la probabilidad de que una lectura errónea de los dígitos pase inadvertida. Los valores extraídos coinciden con los de la imagen y la suma de los cinco boroughs, equivalente a 8.553.679 habitantes, coincide con la fila *New York City*. Los subtotales por sexo difieren del total en una persona debido al redondeo de los promedios. Como validación externa, los resultados se compararon con las estimaciones de

2023 por condado del Departamento de Salud del estado (NYSDOH, 2023). Las cifras extraídas se encuentran entre un 0,1 % por debajo y un 3,5 % por encima, y conservan el mismo orden entre boroughs. Estas diferencias se explican porque la tabla del Registro promedia el periodo 2019–2023, mientras que la fuente de comparación corresponde a un solo año. La suma de 8,55 millones también difiere de los 8.478.000 habitantes de julio de 2024 presentados en la sección 1 por la diferencia de periodo y fuente. La población extraída se utilizará como denominador fijo para 2013–2025, con la limitación de que no representa las variaciones anuales.

4. Exploración de los datos

Esta sección reúne dieciocho análisis realizados con los datos del periodo 2013–2025 (Tabla 30). Los resultados se organizan en cinco dimensiones, vial, climática, espacial, de seguridad y socioeconómica, y se relacionan con las preguntas de negocio de la sección 6. Los valores proceden de las tablas generadas por el cuaderno anexo. Cuando se estimaron a partir de una figura, se presentan como aproximaciones mediante la expresión “cerca de”.

4.1 Dimensión vial

Elemento 1. Severidad de los choques. El 75,3 % de los choques no registra víctimas, el 24,5 % registra personas heridas y el 0,15 % registra personas fallecidas. La distribución presenta una marcada asimetría. El mínimo, la mediana y los percentiles 25 y 75 de las variables de víctimas son cero, mientras que un solo choque puede alcanzar 43 heridos y 8 fallecidos (Tabla 12). Los promedios son de 0,33 heridos y 0,0016 fallecidos por choque, pero están condicionados por pocos casos extremos. Por ello, el índice mide la gravedad mediante la proporción de choques con víctimas y no mediante estos promedios.

Variable (por choque)	Promedio	Desv. estándar	Máximo
Personas heridas	0,332	0,717	43
Personas fallecidas	0,0016	0,042	8
Peatones heridos	0,060	0,251	27
Peatones fallecidos	0,0008	0,029	6
Ciclistas heridos	0,030	0,172	4
Ciclistas fallecidos	0,00013	0,011	2
Motoristas heridos	0,238	0,679	43
Motoristas fallecidos	0,00065	0,028	5

Tabla 12: Estadísticos descriptivos de las variables de víctimas por choque, 2013–2025 (2.132.218 choques)

Elemento 2. Víctimas por tipo de usuario. En el total de choques analizados, el 15,59 % registra conductores o pasajeros heridos o fallecidos, el 5,83 % peatones y el 2,94 % ciclistas (Figura 3). Entre los 516.097 choques cuyas víctimas pudieron clasificarse por tipo de usuario,

512.802 (99,4 %) involucran a un solo grupo, 3.269 a dos y apenas 26 a los tres. Este total es ligeramente inferior al presentado en el elemento 1 porque cerca de 10.000 choques tienen víctimas que el conjunto de datos no asigna a ninguna de estas categorías. La escasa superposición permite medir la gravedad general mediante el total de heridos y fallecidos, mientras que el desglose por usuario se conserva para estudiar por separado a peatones y ciclistas.




Figura 3: Porcentaje de choques con víctimas según el tipo de usuario, 2013–2025

Elemento 3. Choques por día de la semana y hora. La Figura 4 muestra la distribución de los choques ocurridos entre 2013 y 2025 según el día y la hora. En los días hábiles se observa un pico principal entre las 16 y las 17 horas, con el valor más alto los viernes, y otro cerca de las 8 de la mañana. Ambos coinciden con horarios habituales de desplazamiento, aunque el pico matutino desaparece durante el fin de semana. Los sábados y domingos presentan una distribución más uniforme, con una meseta entre las 12 y las 18 horas y mayor actividad de madrugada que los días hábiles. Estos patrones justifican el uso del día y la franja horaria en las ventanas de riesgo. Además, las franjas de seis horas permiten representar los picos de la mañana (06–12) y de la tarde (12–18).




Figura 4: Choques por día de la semana y hora, 2013–2025

Elemento 4. Gravedad según la franja horaria y el tipo de día. La proporción de choques con heridos o fallecidos es mayor entre las 18 y las 24 horas, con cerca del 28,3% en días hábiles y del 28,5% durante el fin de semana. Le sigue la franja 00–06, con el 27,2% y el 27,5%, mientras que 06–12 presenta los valores más bajos, con el 21,7% y el 22,4%, respectivamente (Tabla 13 y Figura 5). Aunque la franja 12–18 concentra la mayor cantidad de choques, con 810.986 casos y el 38 % del total, su gravedad es intermedia. Por tanto, la frecuencia y la gravedad no alcanzan su máximo al mismo tiempo, lo que justifica incluir ambas medidas en el componente vial. Las diferencias entre días hábiles y fines de semana son inferiores a un punto porcentual.

	Entre semana		Fin de semana	
Franja	Choques	% con víctimas	Choques	% con víctimas
00–06	126.219	27,21	99.872	27,46
06–12	456.151	21,74	101.243	22,37
12–18	615.176	23,34	195.810	23,55
18–24	388.747	28,30	149.000	28,52

Tabla 13: Choques y porcentaje con víctimas por franja horaria y tipo de día, 2013–2025




Figura 5: Porcentaje de choques con heridos o fallecidos por franja horaria y tipo de día

4.2 Dimensión climática

Elemento 5. Choques según la condición climática. Al ajustar el número de choques por las horas observadas en cada condición, la nieve y la lluvia presentan tasas superiores a las del cielo despejado. La tasa alcanza 21,75 choques por hora con nieve, cerca de un 21 % más que los 17,98 registrados en condiciones despejadas, y 20,12 con lluvia, cerca de un 12 % más (Tabla 14 y Figura 6). La gravedad no sigue el mismo patrón. La proporción de choques con víctimas es del 19,1 % con nieve, frente al 25,3 % con cielo despejado, y del 25,7 % con lluvia. Por tanto, la nieve se asocia con una mayor frecuencia y una menor gravedad, mientras que la lluvia se relaciona con una mayor frecuencia y una gravedad similar.

Condición	Horas observadas	Choques	Choques por hora	% con víctimas
Nieve	2.097	45.604	21,75	19,08
Lluvia	15.100	303.765	20,12	25,74
Nublado	49.680	936.226	18,85	23,97
Despejado	47.075	846.623	17,98	25,34

Tabla 14: Choques por hora observada y porcentaje con víctimas según la condición climática, 2013–2025




Figura 6: Choques por hora observada y porcentaje de choques con víctimas, según la condición climática

Elemento 6. Clima y franja horaria. La comparación anterior no considera la variación de los choques a lo largo del día. La Tabla 15 repite el cálculo dentro de cada franja para comparar las condiciones climáticas en horarios similares.

- **Nieve.** Presenta más choques por hora en las cuatro franjas, desde un 9 % más entre las 12 y las 18 horas hasta un 23 % más entre las 6 y las 12. También registra una menor proporción de choques con víctimas en todas ellas, como se observa en la franja 12–18, con un 17,4 % frente al 24,5 % en condiciones despejadas.
- **Lluvia.** Presenta más choques por hora durante la madrugada (17 % más) y la noche (13 % más), pero no durante el día. En la mañana el aumento es del 2,5 % y en la tarde se observa una reducción del 2,6 %. Solo entre las 18 y las 24 horas se asocia con una mayor proporción de choques con víctimas, con un 30,6 % frente al 28,3 % en condiciones despejadas.

Franja	Condición	Horas observadas	Choques por hora	% con víctimas
00-06	Despejado	12.880	7,70	27,14
00-06	Lluvia	3.418	8,97	27,57
00-06	Nieve	506	9,27	22,24
00-06	Nublado	11.684	7,84	27,69
06-12	Despejado	12.037	19,69	22,83
06-12	Lluvia	3.675	20,18	22,35
06-12	Nieve	569	24,15	17,22
06-12	Nublado	12.207	19,05	20,97
12-18	Despejado	9.881	28,80	24,47
12-18	Lluvia	4.437	28,04	24,38
12-18	Nieve	540	31,34	17,41
12-18	Nublado	13.630	28,25	22,55
18-24	Despejado	12.277	18,40	28,28
18-24	Lluvia	3.570	20,88	30,64
18-24	Nieve	482	21,26	22,86
18-24	Nublado	12.159	18,67	27,94

Tabla 15: Choques por hora observada y porcentaje con víctimas según la franja horaria y la condición climática, 2013–2025

Estas diferencias representan asociaciones y no efectos causales. Además, su magnitud es menor que la variación por hora descrita en el elemento 3. En todas las condiciones climáticas, la franja 12–18 registra entre tres y cuatro veces más choques por hora que la franja 00–06. Los resultados de la nieve deben interpretarse con cautela, pues cada franja solo cuenta con entre 482 y 569 horas observadas.

Elemento 7. Días con más choques y clima. Los diez registros diarios más altos por borough se concentran en seis fechas (Tabla 16). En cuatro de ellas, el 21 de enero y el 3 de febrero de 2014, el 5 de marzo de 2015 y el 15 de noviembre de 2018, Manhattan registró nevadas de entre 6 y 19 cm. En las otras dos, el 3 de febrero y el 6 de marzo de 2015, casi no hubo nieve, pero la temperatura mínima se aproximó a -15°C . Los valores extremos coinciden así con nevadas o episodios de frío intenso. Este último factor no está representado por las cuatro categorías climáticas utilizadas, por lo que se incorporará en la entrega final. La interpretación debe considerar que el cruce utiliza la serie de Manhattan como referencia para toda la ciudad, según lo definido en la pregunta 3.

Fecha	Borough	Choques	Nieve (cm)	Precip. (mm)	Temp. mín. (°C)
21/01/2014	Brooklyn	254	6,2	8,6	−10,7
03/02/2014	Queens	250	18,7	27,4	−2,9
21/01/2014	Queens	248	6,2	8,6	−10,7
03/02/2015	Brooklyn	247	0,0	0,0	−15,5
03/02/2014	Brooklyn	230	18,7	27,4	−2,9
05/03/2015	Brooklyn	214	9,5	18,8	−6,9
15/11/2018	Queens	214	11,3	21,7	−1,5
15/11/2018	Brooklyn	214	11,3	21,7	−1,5
06/03/2015	Manhattan	209	0,1	0,0	−15,4
05/03/2015	Queens	208	9,5	18,8	−6,9

Tabla 16: Los diez días con más choques en un borough y el clima de Manhattan ese día

4.3 Dimensión espacial

Elemento 8. Choques por población. Brooklyn (473.801) y Queens (396.201) registran los mayores totales de choques. Sin embargo, al ajustar por población, Manhattan presenta la tasa acumulada más alta, con 19.686 choques por cada 100.000 habitantes entre 2013 y 2025, equivalente a cerca de 1.500 por año. Le siguen Brooklyn (17.842), Queens (16.917), el Bronx (15.455) y Staten Island (12.137). Por tanto, el orden de los boroughs cambia al considerar su población (pregunta 4; Tabla 17 y Figura 7).

La interpretación requiere cautela. La tasa de Manhattan utiliza únicamente la población residente y no considera la población que ingresa al borough durante el día, por lo que puede sobrestimar la exposición de sus habitantes. El cálculo también aplica la población promedio de 2019–2023 a todo el periodo y excluye 659.713 choques (30,9 %) sin borough registrado. La proporción de registros excluidos varía del 23,4 % en 2013 al 38,1 % en 2017 y al 19,9 % en 2025 (Tabla 18). Esta variación en la cobertura puede afectar las comparaciones temporales entre boroughs.

Borough	Choques	Población	Choques por 100.000 hab.	
			Acumulado	Por año
Manhattan	322.466	1.638.025	19.686	1.514
Brooklyn	473.801	2.655.570	17.842	1.372
Queens	396.201	2.342.047	16.917	1.301
Bronx	220.044	1.423.729	15.455	1.189
Staten Island	59.993	494.308	12.137	934

Tabla 17: Choques acumulados 2013–2025 y tasa por 100.000 habitantes por borough

Año	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023	2024	2025
% sin borough	23,4	24,1	24,9	33,3	38,1	35,6	35,2	34,7	34,7	33,8	32,0	28,6	19,9

Tabla 18: Porcentaje de choques sin borough registrado por año




Figura 7: Choques por 100.000 habitantes al año (promedio 2013–2025)

Elemento 9. Choques por año y borough. En 2020 los choques cayeron en todos los boroughs y ninguno volvió después a los niveles de 2019 (Figura 8). Brooklyn pasó de 44.479 choques en 2019 a 25.473 en 2020, una reducción del 43 %. Queens disminuyó un 48 %, Manhattan un 59 %, el Bronx un 36 % y Staten Island un 35 %. Entre 2021 y 2024 las cifras se mantuvieron estables o descendieron ligeramente. En 2025 aumentaron en los cinco boroughs respecto a 2024, principalmente en Manhattan, con un 11 % más, y Brooklyn, con un 7 % más. Este quiebre respalda la advertencia sobre el periodo de pandemia incluida en la sección 1.

La figura solo incluye los choques con borough identificado. Esta limitación afecta especialmente la interpretación de Manhattan, cuyos registros disminuyeron un 37 % entre 2015 y 2019, mientras la proporción general de choques sin borough aumentó del 24,9 % al 35,2 % (Tabla 18). Por ello, la caída observada puede reflejar parcialmente una menor completitud de la ubicación y no solo una reducción real de los choques.




Figura 8: Choques por año y borough, 2013–2025 (solo con borough registrado)

Elemento 10. Choques con víctimas por borough. La proporción de choques con heridos o fallecidos varía entre el 19,52 % de Manhattan y el 26,64 % de Brooklyn. El Bronx registra un 25,80 %, Queens un 24,28 % y Staten Island un 22,45 % (Figura 9). El orden por frecuencia no coincide con el de gravedad. Manhattan presenta la mayor tasa de choques por habitante, pero la menor proporción con víctimas, mientras que Brooklyn tiene la proporción más alta y la segunda mayor tasa. Esta diferencia justifica que el componente vial del índice combine ambas medidas (preguntas 2 y 4).




Figura 9: Porcentaje de choques con heridos o fallecidos por borough

4.4 Dimensión de seguridad

Elemento 11. Denuncias graves por día de la semana y hora. Las denuncias por delitos graves siguen un patrón distinto al de los choques (Figura 10). Entre semana aumentan desde el mediodía y alcanzan su máximo entre las 15 y las 19 horas, con el valor más alto los viernes alrededor de las 17 horas. Durante los fines de semana se concentran más en la madrugada, entre las 0 y las 3 horas, y permanecen elevadas en la noche. Los periodos de mayor frecuencia vial y delictiva solo coinciden parcialmente, lo que justifica combinar ambos componentes con pesos diferenciados (pregunta 6).

También se observa un pico aislado al mediodía durante todos los días. A las 12:00:00 exactas se registran 157.594 denuncias, equivalentes al 2,45 % de las que tienen hora, frente a 83.060 a las 11:00:00 y 96.956 a las 13:00:00. Esta concentración sugiere que algunos registros con hora imprecisa se asignaron a las 12:00:00. En cambio, el volumen de las 00:00:00 (63.511) es similar al de la 01:00:00 (59.817), por lo que no se aprecia el mismo patrón a medianoche. Como el mediodía marca el inicio de la franja 12–18, esta posible asignación puede sobrestimar su frecuencia y constituir una limitación del componente de seguridad.




Figura 10: Denuncias por delitos graves (*felony*) por día de la semana y hora, 2013–2025

Elemento 12. Evolución y estacionalidad de las denuncias. Entre 2013 y 2019 el total mensual de denuncias nunca fue inferior a 31.290, valor registrado en febrero de 2015. En abril de 2020 cayó a 25.109, el mínimo de toda la serie, y luego se recuperó hasta alcanzar sus valores más altos en 2024 y 2025. Los máximos fueron 50.914 denuncias en mayo de 2025, 50.810 en julio de 2024 y 50.591 en octubre de 2024 (Figura 11). A diferencia de los choques, que disminuyeron de forma marcada después de 2020, las denuncias aumentaron, lo que revela dinámicas de largo plazo diferentes entre los dos componentes del índice. También se observa estacionalidad. El promedio diario varía entre 1.261 denuncias en febrero y 1.427 en julio, y de mayo a octubre es cerca de 11 % mayor que de diciembre a marzo (Tabla 19).




Figura 11: Evolución mensual de las denuncias, 2013–2025 (la línea punteada marca marzo de 2020)

Mes	1	2	3	4	5	6	7	8	9	10	11	12
Denuncias por día	1.279	1.261	1.292	1.309	1.389	1.421	1.427	1.424	1.419	1.412	1.347	1.264

Tabla 19: Promedio de denuncias por día según el mes del año, 2013–2025

Elemento 13. Gravedad de las denuncias por borough. Los delitos graves (*felony*) representan entre el 30,7 % y el 33,1 % de las denuncias en el Bronx, Brooklyn, Manhattan y Queens, pero solo el 24,9 % en Staten Island (Figura 12). En este último borough, las infracciones (*violation*) alcanzan el 20,4 %, frente a valores de entre el 12,3 % y el 15,5 % en los demás. Los delitos menores (*misdemeanor*) constituyen la categoría más frecuente en los cinco boroughs, con proporciones de entre el 51,4 % y el 55,5 %.




Figura 12: Porcentaje de denuncias por nivel de gravedad en cada borough, 2013–2025

Elemento 14. Arrestos y denuncias por día de la semana. Los arrestos varían mucho más a lo largo de la semana que las denuncias (Tabla 20 y Figura 13). Alcanzan su máximo los miércoles, con 601.851 registros, y su mínimo los domingos, con 354.571, una diferencia cercana al 41 %. Las denuncias presentan una variación menor y oscilan entre 854.094 los domingos y 975.755 los viernes. En consecuencia, la razón entre arrestos y denuncias pasa de 0,415 los domingos a 0,635 los miércoles. Esta diferencia semanal sugiere que el volumen de arrestos refleja tanto la actividad policial como los hechos reportados. Por ello, las denuncias se usarán como medida de riesgo y los arrestos como referencia de la actividad policial (pregunta 7).

Día	Arrestos	Denuncias	Razón arrestos/denuncias
Lunes	398.434	886.061	0,450
Martes	541.972	920.580	0,589
Miércoles	601.851	947.850	0,635
Jueves	571.922	927.883	0,616
Viernes	520.443	975.755	0,533
Sábado	446.314	916.989	0,487
Domingo	354.571	854.094	0,415

Tabla 20: Arrestos y denuncias por día de la semana, 2013–2025




Figura 13: Arrestos y denuncias por día de la semana, 2013–2025

Elemento 15. Arrestos y denuncias por borough. En los cinco boroughs se registra aproximadamente un arresto por cada dos denuncias. La razón varía entre 0,478 en Staten Island y 0,573 en Manhattan (Tabla 21 y Figura 14). Estas diferencias son menores que las observadas entre días de la semana, por lo que el análisis final examinará la relación por borough, día y franja horaria (pregunta 7).

Borough	Arrestos	Denuncias	Razón arrestos/denuncias
Manhattan	888.997	1.551.510	0,573
Bronx	768.730	1.397.131	0,550
Queens	693.736	1.338.710	0,518
Brooklyn	949.189	1.854.564	0,512
Staten Island	134.855	282.208	0,478

Tabla 21: Arrestos y denuncias por borough, 2013–2025




Figura 14: Arrestos y denuncias por borough, 2013–2025

Elemento 16. Denuncias graves por población. Brooklyn registra el mayor número total de denuncias graves, con 612.975. Sin embargo, al ajustar por población, Manhattan y el Bronx presentan las tasas anuales más altas, con 2.345 y 2.318 denuncias por cada 100.000 habitantes, respectivamente. Les siguen Brooklyn con 1.776, Queens con 1.449 y Staten Island con 1.094 (Tabla 22 y Figura 15). Este orden difiere del observado en los choques. El Bronx ocupa el segundo lugar en denuncias graves por habitante, pero el cuarto en choques, con 1.189 por cada 100.000 habitantes al año. Por tanto, los dos componentes señalan prioridades espaciales distintas y deben ponderarse por separado (pregunta 9). Se mantienen las cautelas del elemento 8 sobre el uso de la población residente y del promedio de 2019–2023.

Borough	Denuncias graves	Población	Denuncias graves por 100.000 hab.	
			Acumulado	Por año
Manhattan	499.421	1.638.025	30.489	2.345
Bronx	428.982	1.423.729	30.131	2.318
Brooklyn	612.975	2.655.570	23.083	1.776
Queens	441.146	2.342.047	18.836	1.449
Staten Island	70.289	494.308	14.220	1.094

Tabla 22: Denuncias graves acumuladas 2013–2025 y tasa por 100.000 habitantes por borough




Figura 15: Denuncias graves por 100.000 habitantes al año (promedio 2013–2025)

Elemento 17. Composición de las denuncias graves. Los diez delitos más frecuentes reúnen el 93,7 % de las denuncias graves (Tabla 23). El hurto mayor (*grand larceny*) ocupa el primer lugar con el 28,35 %, seguido de la agresión grave con el 14,63 % y el robo con violencia con el 9,82 %. La categoría de otras infracciones al código penal, que agrupa conductas diversas, representa el 9,05 %. En conjunto, los delitos contra la propiedad suman el 50,5 %, mientras que la agresión grave y el robo alcanzan el 24,5 %. El componente de seguridad refleja, por tanto, principalmente delitos contra la propiedad y no solo hechos violentos. Esta composición se considerará al definir su peso en el índice y al evaluar una posible separación por tipo de delito en la entrega final.

Delito (<i>OFNS_DESC</i>)	Denuncias	% de las graves
<i>Grand larceny</i> (hurto mayor)	582.007	28,35
<i>Felony assault</i> (agresión grave)	300.434	14,63
<i>Robbery</i> (robo con violencia)	201.583	9,82
<i>Miscellaneous penal law</i> (otras infracciones penales)	185.857	9,05
<i>Burglary</i> (allanamiento)	181.076	8,82
<i>Criminal mischief & related</i> (daño criminal)	151.771	7,39
<i>Grand larceny of motor vehicle</i> (hurto mayor de vehículo)	121.775	5,93
<i>Dangerous drugs</i> (drogas peligrosas)	69.709	3,40
<i>Forgery</i> (falsificación)	67.264	3,28
<i>Dangerous weapons</i> (armas peligrosas)	62.738	3,06

Tabla 23: Los diez delitos graves más frecuentes en las denuncias, 2013–2025

4.5 Dimensión socioeconómica

Elemento 18. Pobreza por borough. La tasa de pobreza NYCgov de 2018, calculada con los pesos muestrales, alcanza su valor más alto en el Bronx con el 27,1 %, seguido de Brooklyn con el 20,3 %. Las tasas de Queens, Staten Island y Manhattan son del 17,0 %, 16,0 % y 15,1 %, respectivamente (Tabla 24 y Figura 16). Para toda la ciudad, el cálculo produce una tasa del 19,3 %, cercana al 19,1 % publicado por la ciudad para 2018 (NYC Opportunity, s.f.), lo que respalda la consistencia del procedimiento de ponderación. El orden no coincide por completo con el indicador de la encuesta ACS de 2024 presentado en la Tabla 1. La diferencia se explica porque corresponden a años y medidas distintas, con umbrales y definiciones de ingreso propios. El Bronx presenta la tasa más alta en ambas fuentes. Esta variable se utilizará como contexto para comparar las ventanas de mayor urgencia (pregunta 8).

Borough	Tasa de pobreza NYCgov 2018 (%)
Bronx	27,12
Brooklyn	20,31
Queens	17,02
Staten Island	16,00
Manhattan	15,12

Tabla 24: Tasa de pobreza por borough según la medida NYCgov (2018), con pesos muestrales




Figura 16: Tasa de pobreza por borough, medida NYCgov 2018

4.6 Síntesis de la exploración

En conjunto, la exploración muestra que el riesgo vial varía principalmente según la hora y el día de la semana, y que cerca de una cuarta parte de los choques deja víctimas. La frecuencia y la gravedad no coinciden en el tiempo ni en el espacio. La franja 12–18 concentra más choques, pero las franjas 18–24 y 00–06 presentan una mayor proporción con víctimas. Asimismo, Manhattan tiene la tasa más alta de choques por habitante y la menor proporción con víctimas.

El clima introduce variaciones moderadas que dependen de la franja horaria. La nieve se asocia con más choques por hora, pero con una menor proporción de víctimas, y los días extremos coinciden con nevadas o frío intenso. El ajuste por población también cambia el orden

de los boroughs. El Bronx, por ejemplo, ocupa el cuarto lugar en choques y el segundo en denuncias graves. Estas denuncias corresponden principalmente a delitos contra la propiedad, mientras que la variación semanal de los arrestos sugiere una influencia importante de la actividad policial. Los hallazgos orientan las preguntas de negocio de la sección 6 y las decisiones de preparación de datos de la sección 7.

5. Reporte de calidad de datos

La calidad de los datos se evaluó mediante el número y el porcentaje de valores faltantes de cada atributo. Se consideraron como faltantes los valores nulos, las cadenas vacías y el texto (`null`) presente en el conjunto de denuncias. El cálculo se realizó en Spark sobre los datos originales, antes de aplicar los filtros de la sección 7. El reporte completo de atributos se encuentra en el cuaderno anexo y la Tabla 25 presenta el total de registros de cada conjunto.

Conjunto de datos	Registros
Motor Vehicle Collisions – Crashes	2.269.187
NYPD Arrest Data	6.264.978
NYPD Complaint Data Historic	10.071.507
NYCgov Poverty Measure	68.273
Open-Meteo (clima por hora)	601.320
Población por borough	5

Tabla 25: Conteo de registros por conjunto de datos

Choques (*Crashes*)

Variable	Faltantes	%	Tratamiento propuesto
BOROUGH	691.375	30,47	Recuperar a partir de las coordenadas cuando existan; excluir los registros sin borough ni coordenadas.
LATITUDE	240.806	10,61	Convertir a número (el texto usa coma decimal); si falta junto con el borough, excluir el registro.
LONGITUDE	240.806	10,61	Igual que la latitud.
NUMBER OF PERSONS KILLED	8.913	0,39	Asumir 0.
NUMBER OF PERSONS INJURED	18	~0	Asumir 0.
CONTRIBUTING FACTOR VEHICLE 1	8.202	0,36	Establecer como UNKNOWN.
CRASH DATE, CRASH TIME, COLLISION_ID	0	0	No requieren tratamiento.

Tabla 26: Reporte de valores faltantes – Crashes

La variable de delimitación espacial (BOROUGH) carece de información en casi un tercio de los registros. Como las coordenadas faltan solo en el 10,61 %, una parte importante de los valores ausentes de borough puede recuperarse a partir de la ubicación. Los registros que no tienen borough ni coordenadas se excluyen. Los atributos de los vehículos y los factores contribuyentes del tercero al quinto presentan más del 92 % de faltantes y no son necesarios para el objetivo de negocio. Por ejemplo, VEHICLE TYPE CODE 5 alcanza el 99,56 %. Tampoco se utiliza OFF STREET NAME, que tiene un 82,07 % de faltantes.

Arrestos (*Arrests*)

Variable	Faltantes	%	Tratamiento propuesto
ARREST_DATE	0	0	No requiere tratamiento.
ARREST_PRECINCT	0	0	No requiere tratamiento.
ARREST_BORO	8	~0	Etiquetar como UNKNOWN y excluir de los análisis por borough.
Latitude, Longitude	5	~0	No se usan en el índice (la unidad espacial es el borough).
LAW_CAT_CD	26.474	0,42	Establecer como UNKNOWN.
OFNS_DESC	9.811	0,16	Establecer como UNKNOWN.

Tabla 27: Reporte de valores faltantes – NYPD Arrest Data

El conjunto de arrestos está prácticamente completo en las variables espacio-temporales requeridas, como la fecha y el borough. Los faltantes de LAW_CAT_CD y OFNS_DESC se etiquetan como UNKNOWN al clasificar el delito asociado con el arresto. Los atributos demográficos con mayor proporción de faltantes, AGE_GROUP y PERP_SEX con el 2,35 %, no se utilizan en el índice.

Denuncias (*Complaints*)

Variable	Faltantes	%	Tratamiento propuesto
CMPLNT_FR_DT	655	0,01	Excluir del análisis.
CMPLNT_FR_TM	48	~0	Excluir del análisis por franja horaria.
BORO_NM	10.078	0,10	Recuperar a partir de las coordenadas cuando existan; si no, excluir.
Latitude, Longitude	479	~0	Excluir si falta también el borough.
LAW_CAT_CD	0	0	No requiere tratamiento.

Tabla 28: Reporte de valores faltantes – NYPD Complaint Data Historic

Cinco atributos superan el 90 % de valores faltantes. HADEVELOPT alcanza el 99,65 %, PARKS_NM el 99,56 %, TRANSIT_DISTRICT y STATION_NAME el 97,42 %, y HOUSING_PSA el 92,63 %. Estas variables no se consideran porque no son necesarias para el objetivo de negocio. Los atributos del sospechoso también presentan una proporción elevada de faltantes, entre el 37,84 % y el 46,75 %, pero tampoco se utilizan.

Pobreza, clima y población

Variable	Faltantes	%	Tratamiento propuesto
Pobreza – Boro, NYCgov_Pov_Stat, PWGTP	0	0	No requieren tratamiento.
Pobreza – ENG	37.557	55,01	No se usa.
Pobreza – JWTR	34.956	51,20	No se usa.
Pobreza – WKW	31.394	45,98	No se usa.
Clima – visibility	601.320	100	Descartar la variable.
Clima – demás variables	0	0	No requieren tratamiento.
Población – todas las variables	0	0	No requieren tratamiento.

Tabla 29: Reporte de valores faltantes – Pobreza, clima y población

En el conjunto de pobreza están completas las variables necesarias para el proyecto, correspondientes al borough, la condición de pobreza y el peso muestral. Los faltantes de otros atributos, como ENG, JWTR y WKW, provienen de preguntas que no se aplican a toda la población, por ejemplo a quienes no trabajan, y no representan errores de captura. En los datos climáticos, la visibilidad llegó vacía en todos los registros obtenidos mediante la API y se descarta. Las demás variables están completas.

6. Planteamiento de preguntas sobre los datos

1. ¿Cuáles son las cinco ventanas de riesgo con mayor frecuencia de choques, teniendo en cuenta el borough, la franja horaria, el día de la semana, la condición climática y las horas observadas?
2. ¿En qué días y franjas horarias se presenta la mayor proporción de choques con personas heridas o fallecidas, y cómo cambia este patrón entre boroughs?
3. ¿La lluvia o la nieve se relacionan con una mayor proporción de choques graves frente a las condiciones despejadas, después de considerar cuántas horas se observó cada tipo de clima?
4. ¿Cómo cambia la clasificación de los boroughs con más choques cuando los resultados se ajustan por población, en comparación con los conteos absolutos?
5. ¿Cuáles son las cinco ventanas con mayor frecuencia de denuncias por delitos graves, teniendo en cuenta las horas observadas?
6. ¿En qué días y franjas horarias se concentran las denuncias por delitos graves, y coinciden estos periodos con los de mayor riesgo vial?
7. ¿Cómo cambia entre boroughs y días de la semana la relación entre el número de arrestos y el número de denuncias, y dónde se presentan las mayores diferencias entre la actividad policial y los hechos reportados?
8. ¿Los boroughs que concentran las ventanas de mayor urgencia también presentan los niveles más altos de pobreza según la medida de 2018?

9. ¿Cuánto cambia el orden de las ventanas de riesgo cuando se modifican los pesos asignados al componente vial y al componente de seguridad?
10. ¿Cuántas ventanas concentran la mitad de la urgencia total y qué porcentaje representan frente al total de ventanas analizadas?

7. Filtros, limpieza y transformación inicial

Esta sección presenta el avance en la preparación de los datos. Los procesos se implementaron en Spark y se documentan en el cuaderno anexo. La preparación completa, incluida la construcción de las ventanas de riesgo, se desarrollará en la entrega final.

7.1 Filtros

Los filtros 1 y 2 se aplicaron a los datos de la exploración (sección 4). El filtro 3 forma parte de la limpieza del conjunto de choques que se guardó para la entrega final.

1. **Fecha válida.** Se conservaron únicamente los registros cuya fecha tiene el formato MM/DD/AAAA. Esto evita errores al convertir la fecha y descarta registros sin fecha utilizable.
2. **Periodo de análisis.** Se conservaron los registros comprendidos entre 2013 y 2025. Como las fuentes cubren periodos diferentes, se seleccionaron los años completos comunes a las tres. Los arrestos comienzan en 2006, los choques en 2012 y las denuncias incluyen registros anteriores a 2013.
3. **Ubicación mínima en choques.** Se conservaron los registros con borough o coordenadas. Se descartaron aquellos que no tienen ninguna de estas referencias y los que presentan coordenadas fuera de un rango geográfico válido.

La Tabla 30 muestra cuántos registros se descartaron en los dos primeros filtros.

Conjunto	Originales	Fecha inválida	Fuera de 2013–2025	Usados
Choques (<i>Crashes</i>)	2.269.187	0	136.969	2.132.218
Denuncias (<i>Complaints</i>)	10.071.507	655	3.641.640	6.429.212
Arrestos (<i>Arrests</i>)	6.264.978	0	2.829.471	3.435.507

Tabla 30: Registros antes y después de cada filtro

Los 655 registros de denuncias descartados por fecha inválida corresponden a los valores faltantes de `CMPLNT_FR_DT` reportados en la sección 5. En los conjuntos de choques y arrestos no se descartaron registros por este motivo.

7.2 Limpieza

- **Lectura del archivo de choques.** Una lectura simple dividía las filas que contenían saltos de línea dentro de campos de texto entre comillas. Esto generaba registros truncados y hacía que algunas columnas numéricas se interpretaran como texto. Las opciones `multiLine` y `escape` permiten leer completas estas filas, conservar como enteros las columnas de conteo y evitar pérdidas por errores de formato.
- **Valores nulos.** Los campos vacíos y el texto (`null`), presente en el conjunto de denuncias, se convierten en valores nulos para tratar de manera uniforme los datos faltantes.

- **Llaves duplicadas.** Se verificó la unicidad de `COLLISION_ID`, `CMPLNT_NUM` y `ARREST_KEY`. No se encontraron duplicados en choques ni en arrestos. En denuncias hay dos registros con una llave repetida, equivalentes a cerca del 0,00003 % del total. El proceso de limpieza elimina las llaves duplicadas en los tres conjuntos.
- **Faltantes de severidad.** En los choques, los valores faltantes de personas heridas y fallecidas se reemplazan por 0, y el factor contribuyente faltante se etiqueta como `UNKNOWN`. En los arrestos, la categoría y la gravedad del delito se normalizan mediante la eliminación de espacios y la conversión a mayúsculas. Sus valores faltantes también se etiquetan como `UNKNOWN`.

7.3 Transformaciones

1. **Fechas y horas.** Las fechas en texto se convierten al tipo fecha y se extrae la hora, entre 0 y 23, de los choques y las denuncias. En estas últimas, la fecha y la hora se combinan en una sola marca temporal. Así se puede derivar el día de la semana y cruzar los registros con el clima según la fecha y la hora.
2. **Estandarización del borough.** Se crea una columna con el nombre del borough en mayúsculas. En el conjunto de arrestos, donde se representa mediante una letra (B, K, M, Q, S), cada código se traduce al nombre correspondiente.
3. **Franja horaria.** A partir de la hora se crea la franja de seis horas (00–06, 06–12, 12–18 y 18–24), que es una de las dimensiones de la ventana de riesgo (Código 1).
4. **Coordenadas.** La latitud y la longitud de los choques, almacenadas como texto con coma decimal, se convierten a valores numéricos.
5. **Recuperación del borough.** Cuando falta el borough pero existen coordenadas, la ubicación se asigna según los rangos de latitud y longitud de cada borough. Esta situación afecta a 691.375 choques y 10.078 denuncias. La aproximación es provisional porque los rangos de boroughs vecinos se solapan en las zonas limítrofes y pueden producir asignaciones incorrectas. En la entrega final se refinará el procedimiento mediante los polígonos oficiales de los boroughs.
6. **Normalización por población.** Los conteos por borough se dividen entre la población para expresarlos como tasas por 100.000 habitantes (elemento 8 de la sección 4).

Listing 1: Funciones de limpieza de nulos y de franja horaria (PySpark)

```
def limpia_nulos(df, cols):
    # Convierte "" y "(null)" en nulo real
    for c in cols:
        df = df.withColumn(c, F.when(
            F.trim(F.col(c).cast("string")).isin("", "(null)"),
            F.lit(None)).otherwise(F.col(c)))
    return df

def franja(hora):
    # Franja horaria de 6 horas
    return (F.when(hora.isNull(), F.lit(None))
            .when(hora < 6, "00-06").when(hora < 12, "06-12")
            .when(hora < 18, "12-18").otherwise("18-24"))
```

7.4 Resultado y pendientes

El conjunto limpio de choques se guardó en el archivo `data/processed/crashes_processed.csv`. Los análisis de la sección 4 se calcularon con los filtros 1 y 2 y con las transformaciones 1 a 3, aplicados sobre los datos originales. La limpieza descrita en esta sección (ubicación mínima, coordenadas, recuperación del borough y valores faltantes) generó el conjunto procesado de choques, que se usará en la entrega final.

- Incorporar el filtro de 2013 a 2025 en los conjuntos limpios persistidos, que todavía incluyen años anteriores. Los choques comienzan en 2012, los arrestos en 2006 y las denuncias en 2005.
- Registrar cuántos registros se descartan en cada paso de la limpieza (por ejemplo, el filtro de ubicación mínima de los choques).
- Excluir de las denuncias las que siguen sin borough tras usar las coordenadas, como ya se hace con choques y arrestos.
- Refinar la recuperación del borough de choques y denuncias.
- Convertir a formato numérico las coordenadas de arrestos y las columnas de ingreso del conjunto de pobreza.
- Construir las ventanas de riesgo (borough, franja horaria, día de la semana y condición climática) y calcular las horas observadas de cada una.

8. Conclusiones preliminares y próximos pasos

El análisis preliminar respalda la viabilidad del índice de urgencia propuesto. En el componente vial, cerca de una cuarta parte de los choques deja víctimas. El 24,5 % registra personas heridas y el 0,15 % personas fallecidas, por lo que la gravedad debe expresarse como una proporción y no solo mediante conteos. La frecuencia y la gravedad tampoco alcanzan su máximo en las mismas condiciones. La franja 12–18 concentra más choques, mientras que 18–24 y 00–06 presentan la mayor proporción con víctimas. En el ámbito espacial, Manhattan tiene la tasa más alta de choques por habitante, pero la menor proporción con víctimas. Estos resultados justifican que el componente vial combine ambas medidas.

La relación entre el clima y los choques depende de la franja horaria. La nieve se asocia con incrementos de entre el 9 % y el 23 % en los choques por hora, pero con una menor proporción de víctimas. La lluvia se relaciona con aumentos principalmente durante la noche y la madrugada, y los días con más choques coinciden con nevadas o frío intenso. También existen diferencias de largo plazo. Los choques disminuyeron de forma marcada en 2020 y no regresaron a los niveles anteriores, mientras que las denuncias aumentaron. Por tanto, los dos componentes del índice deben considerar dinámicas temporales distintas.

En el componente de seguridad, el ajuste por población modifica el orden de los boroughs. Manhattan y el Bronx presentan las mayores tasas de denuncias graves, con cerca de 2.300 por cada 100.000 habitantes al año. El Bronx ocupa el cuarto lugar en choques y el segundo en denuncias graves, lo que confirma que ambos componentes señalan prioridades espaciales diferentes. Los delitos contra la propiedad representan el 50,5 % de las denuncias graves, mientras que la agresión grave y el robo suman el 24,5 %. Los arrestos, además, varían mucho más que las denuncias a lo largo de la semana y son cerca de un 41 % menos numerosos los domingos que los miércoles. Este patrón respalda el uso de las denuncias como medida de riesgo y de los arrestos como referencia de la actividad policial. El Bronx también registra la mayor tasa de pobreza, con el 27,1 %, lo que permitirá evaluar la relación entre urgencia y vulnerabilidad socioeconómica.

La interpretación de estos resultados debe considerar tres limitaciones principales. El 30,9 % de los choques no tiene borough registrado, algunas denuncias con hora imprecisa pueden haberse asignado al mediodía y la normalización utiliza la población promedio de 2019–2023. En las siguientes fases de CRISP-DM se construirán las ventanas de riesgo y se calcularán sus horas observadas. Después se estimará el índice con diferentes pesos, se evaluará su sensibilidad, se responderán las preguntas de negocio y se desarrollarán los modelos con Spark MLlib.

Bibliografía

Abeyratne, D., y Halgamuge, M. N. (2020).

Applying Big Data Analytics on Motor Vehicle Collision Predictions in New York City.

En *Intelligent Data Analysis: From Data Gathering to Data Comprehension*. Wiley.

Disponible en: <https://doi.org/10.1002/9781119544487.ch11>

Cappellari, P., y Weber, B. S. (2022).

An analysis of the New York City traffic volume, vehicle collisions, and safety under COVID-19.

Journal of Safety Research, 83.

Disponible en: <https://doi.org/10.1016/j.jsr.2022.08.004>

Chang, H., Xu, C. K., y Tang, T. (2024).

Investigating the Temporal Dynamics of Motor Vehicle Collision Density Patterns in Urban Road Networks – A Case Study of New York.

Journal of Safety Research, 89, 116–134.

Disponible en: <https://doi.org/10.1016/j.jsr.2024.02.009>

Dragan, K. L., et al. (2024).

Major Traffic Safety Reform and Road Traffic Injuries Among Low-Income New York Residents.

American Journal of Public Health, 114(6), 633–641.

Disponible en: <https://doi.org/10.2105/AJPH.2024.307617>

Elluri, L., Mandalapu, V., y Roy, N. (2019).

Developing Machine Learning Based Predictive Models for Smart Policing.

En *2019 IEEE International Conference on Smart Computing (SMARTCOMP)*. IEEE.

Disponible en: <https://doi.org/10.1109/SMARTCOMP.2019.00053>

Hersbach, H., Bell, B., Berrisford, P., et al. (2020).

The ERA5 global reanalysis.

Quarterly Journal of the Royal Meteorological Society, 146(730), 1999–2049.

Disponible en: <https://doi.org/10.1002/qj.3803>

Mittal, V., y Lim, E. (2024).

Patterns and Analysis of Traffic Accidents in New York City between 2013 and 2023.

Urban Science, 8(4), 166.

Disponible en: <https://doi.org/10.3390/urbansci8040166>

New York City Department of City Planning. (2025).

New York City Population Estimates and Trends. Mayo de 2025.

Disponible en: https://s-media.nyc.gov/agencies/dcp/assets/files/pdf/data-tools/population/population-estimates/new-york-city-population-estimates-and-trends_may-2025.pdf

New York City Department of Transportation. (2025).

Vision Zero: NYC DOT Announces Traffic Deaths Reached Lowest Level in Recorded History During the First Six Months of 2025, Fatalities Down 32 Percent From Last Year. Comunicado de prensa, 2 de julio.

Disponible en: <https://www.nyc.gov/html/dot/html/pr2025/vision-zero.shtml>

New York City Department of Transportation. (2026).

Traffic Deaths are Down 31 Percent Since Vision Zero Launched in 2014. Comunicado de prensa, 2 de enero.

Disponibile en: <https://www.nyc.gov/html/dot/html/pr2026/traffic-deaths-reach-all-time-low.shtml>

New York City Department of Transportation. (2026).

Vision Zero: Mamdani Administration Announces Pedestrian Deaths at Historic Low and That First Half of 2026 Among Safest Years on Record. Comunicado de prensa.

Disponibile en: <https://www.nyc.gov/html/dot/html/pr2026/vision-zero-pedestrian-deaths-at-historic-low.shtml>

NYC Open Data. (s.f.). Motor Vehicle Collisions – Crashes.

Disponibile en: https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Crashes/h9gi-nx95/about_data

NYC Open Data. (s.f.). NYPD Complaint Data Historic.

Disponibile en: https://data.cityofnewyork.us/Public-Safety/NYPD-Complaint-Data-Historic/qgea-i56i/about_data

NYC Open Data. (s.f.). NYPD Arrests Data (Historic).

Disponibile en: https://data.cityofnewyork.us/Public-Safety/NYPD-Arrests-Data-Historic-/8h9b-rp9u/about_data

NYC Open Data. (s.f.). NYCgov Poverty Measure Data (2018).

Disponibile en: https://data.cityofnewyork.us/City-Government/NYCgov-Poverty-Measure-Data-2018-/cts7-vksw/about_data

NYC Mayor's Office for Economic Opportunity. (s.f.).

New York City Government Poverty Measure 2018.

Disponibile en: <https://a860-gpp.nyc.gov/downloads/6969z373n?locale=en>

New York City Police Department. (2025).

Crime down across New York City in 2024. Comunicado de prensa, 6 de enero.

Disponibile en: <https://www.nyc.gov/site/nypd/news/pr001/crime-down-across-new-york-city-in-2024>

New York City Police Department. (2025).

Motor Vehicle Collision Report Statistics – Citywide.

Disponibile en: https://home4.nyc.gov/assets/nypd/downloads/pdf/traffic_data/cityacc.pdf

New York State Department of Health. (s.f.).

New York State Cancer Registry: Population Estimates.

Disponibile en: <https://www.health.ny.gov/statistics/cancer/registry/population.htm>

New York State Department of Health. (2023).

Table 2: Estimated Population, Land Area, and Population Density by County, New York State – 2023. Vital Statistics of New York State.

Disponible en: https://healthweb-back.health.ny.gov/statistics/vital_statistics/2023/table02.htm

New York City Rent Guidelines Board. (2026).

2026 Income and Affordability Study. Abril de 2026.

Disponible en: <https://rentguidelinesboard.cityofnewyork.us/wp-content/uploads/2026/04/2026-IA.pdf>

Sehtman-Shachar, S., Billig, P. C., Stein, A., y Kaplan, S. (2024).

The immediate effects of vision-zero corridor upgrades on pedestrian crashes in New York: A before-and-after spatial point process approach.

Accident Analysis & Prevention.

Disponible en: <https://www.sciencedirect.com/science/article/abs/pii/S0001457524000769>

Williamson, D. (2018).

Policing by Place: A Proposed Multi-level Analysis of the Effectiveness of Risk Terrain Modeling for Allocating Police Resources, 2014-2015 [New York City] (ICPSR 36899). Inter-university Consortium for Political and Social Research.

Disponible en: <https://doi.org/10.3886/ICPSR36899.v1>

Zhu, D., Xie, C., Wang, Z., y Zhang, H. (2025).

RaX-Crash: A Resource Efficient and Explainable Small Model Pipeline with an Application to City Scale Injury Severity Prediction.

Preprint, arXiv:2512.07848.

Disponible en: <https://arxiv.org/abs/2512.07848>

Zippenfenig, P. (2023).

Open-Meteo.com Weather API. Zenodo.

Disponible en: <https://doi.org/10.5281/zenodo.7970649>